

**«Санкт-Петербургский государственный электротехнический университет
«ЛЭТИ» им. В.И.Ульянова (Ленина)»
(СПбГЭТУ «ЛЭТИ»)**

**ОТЧЁТ ПО 1 ПРАКТИЧЕСКОЙ РАБОТЕ АНАЛИЗ И
ИНТЕРПРИТАЦИЯ ДАННЫХ
ВАРИАНТ №15**

Студент гр. 1310

подпись

Комаров Д.Е.

Студент гр. 1310

подпись

Прахов Д. А.

Руководитель

подпись

Альсова О.К.

Санкт-Петербург

2026

1. Постановка задачи:

Исследуется рынок потребителей услуги «Подключение к сети Интернет». Для проведения статистического исследования предоставлена БД, включающая 200 записей (наблюдений), каждая из которых содержит описание потребителя услуг. Все потребители разделены на две равные группы (100 записей в каждой группе). Рассматриваются следующие показатели (признаки) для каждого потребителя:

- Group – группа (1, 2);
- Gender - пол (1-м, 2-ж);
- Age - возраст;
- Work experience - стаж работы (время использования услуги);
- Average income - средний доход;
- Professional specialization - профессиональная специализация (насколько часто используется сеть Интернет в профессиональной деятельности): 1 – не использую; 2 – крайне редко; 3 – ежедневно, 4 – постоянно;
- Average number of pages - среднее количество просматриваемых страниц в месяц;
- Activity level (score) - степень активности (участие в Интернет-опросах, баллы);
- Activity level (level) - степень активности (участие в Интернет-опросах, качественная оценка);

Необходимо провести предварительный разведочный анализ данных, графический анализ данных с целью описания характера распределения и структуры данных по выделенным группам потребителей, сравнения потребителей по группам

2. Расчет основных статистических характеристик для первой и второй группы и для всей выборки.

Код :

```
df <- read.csv2("var_15.csv")
df <- df[, -1]
#3
names(df)[names(df) == "Average.income"] <- "Average income"
names(df)[names(df) == "Work.experience"] <- "Work experience"
names(df)[names(df) == "Professional.specialization"] <- "Professional specialization"
names(df)[names(df) == "Average.number.of.pages"] <- "Average number of pages"
names(df)[names(df) == "Activity.level..score."] <- "Activity level (score)"
names(df)[names(df) == "Activity.level..level."] <- "Activity level (level)"
#4
df$"Group" <- as.factor(df$"Group")
df$"Gender" <- as.factor(df$"Gender")
df$"Age" <- as.integer(df$"Age")
df$"Work experience" <- as.numeric(df$"Work experience")
df$"Average income" <- as.numeric(df$"Average income")
df$"Professional specialization" <- as.factor(df$"Professional specialization")
df$"Average number of pages" <- as.integer(df$"Average number of pages")
df$"Activity level (score)" <- as.integer(df$"Activity level (score)")
df$"Activity level (level)" <- as.factor(df$"Activity level (level)")
print(str(df))
#5
print(summary(df))
```

Результат выполнения кода представлен на рис. 1.

```
> print(str(df))
'data.frame': 200 obs. of 9 variables:
 $ Group      : Factor w/ 2 levels "1","2": 1 1 1 1 1 1 1 1 1 ...
 $ Gender     : Factor w/ 2 levels "1","2": 1 2 2 2 1 1 2 2 2 ...
 $ Age        : int 21 24 22 22 23 23 22 23 24 22 ...
 $ Average income : num 27.9 28.8 34.6 31.7 28 33.4 29.7 29.3 29.6 27.1 ...
 $ Work experience : num 9.2 9.5 11.3 7.8 5.9 8.2 7.7 6.3 8.4 6.9 ...
 $ Professional specialization: Factor w/ 4 levels "1","2","3","4": 4 1 4 2 3 2 4 4 3 3 ...
 $ Average number of pages : int 1391 1406 1685 1162 914 1249 1150 944 1205 1011 ...
 $ Activity level (score) : int 82 83 81 74 83 81 81 77 81 81 ...
 $ Activity level (level) : Factor w/ 3 levels "High","Low","Medium": 1 1 1 3 1 1 1 1 1 1 ...
NULL
> #5
> print(summary(df))
 Group   Gender   Age   Average income   work experience   Professional specialization
1:100    1: 77   Min.    :20.00   Min.    :24.00   Min.    : 1.80   1:30
2:100    2:123  1st Qu.:23.00  1st Qu.:29.88  1st Qu.: 7.80   2:59
              Median :29.00  Median :35.75  Median :11.70   3:66
              Mean   :31.34  Mean   :45.59  Mean   :13.94   4:45
              3rd Qu.:40.00  3rd Qu.:59.10  3rd Qu.:20.20
              Max.   :47.00  Max.   :98.40  Max.   :32.00
Average number of pages Activity level (score) Activity level (level)
Min.    : 248              Min.    : 39.00             High :120
1st Qu.:1194              1st Qu.: 69.75             Low  : 39
Median :1765              Median : 78.00             Medium: 41
Mean   :2094              Mean   : 75.02
3rd Qu.:3037              3rd Qu.: 83.00
Max.   :4823              Max.   :100.00
```

Рисунок 1 – Вывод с п.1 по п.5

Основываясь на полученных результатах, можно сделать следующие выводы:

- Выборка четко разделена на две возрастные категории. Первая группа представляет молодежь (в среднем ~23 года) с небольшим разбросом по возрасту, в то время как вторая группа состоит из более зрелых пользователей (в среднем ~40 лет).
- Наблюдается логичная взаимосвязь: пользователи из второй (более старшей) группы имеют существенно более высокий средний доход (60.54 против 30.64) и стаж использования услуг/работы (19.93 против 7.94). При этом во второй группе разброс доходов значительно выше (стандартное отклонение 14.75 против 3.17 в первой группе).
- Пользователи второй группы просматривают в среднем в 2.5 раза больше страниц в месяц (около 3000), чем пользователи первой группы (около 1200).
- Несмотря на меньший объем просматриваемых страниц, молодежь из первой группы демонстрирует более высокую степень активности в опросах (средний балл 81.04 против 68.99 у второй группы) и более стабильна в этом показателе (стандартное отклонение 5.55 против 14.47).
- Значительные отрицательные значения эксцесса (около -1) по возрасту, доходу, стажу и количеству страниц для всей выборки в целом указывают на плосковершинное распределение. Это подтверждает неоднородность общей выборки и явное наличие двух разных подгрупп с различными центрами распределения (бимодальность).

3. Графический разведочный (первичный) анализ данных.

Код:

```
#6.1
```

```
dev.new()
```

```
plot(df$"Work experience", df$"Average income", main = "Диаграмма рассеяния", xlab =  
"Стаж работы", ylab = "Средний доход", pch = 11)
```

Результат выполнения кода представлен на рис.2.




Рисунок 2 - диаграмму рассеяния по среднему доходу и стажу работы.

Наблюдается четкое разделение выборки на два кластера. В левом нижнем углу сгруппированы пользователи с небольшим стажем и низким доходом (первая группа). Второй кластер более рассеян и показывает прямую линейную зависимость: с ростом стажа увеличивается доход (вторая группа).

Код:

```
#6.2
```

```
dev.new()
```

```
x <- c(summary(df$"Professional specialization"))
```

```
piepercent <- round(100*x/sum(x), 1)
```

```
pie(x, piepercent, main = "Профессиональная специализация", col = c("red",  
"blue", "green", "yellow"), clockwise = TRUE)
```

```
legend("topright", c("Не использую", "Крайне редко", "Ежедневно", "Постоянно"), fill  
= c("red", "blue", "green", "yellow"))
```

Результат выполнения кода представлен на рис.3.

Профессиональная специализация



Рисунок 3 - радиальная диаграмма

Распределение пользователей по частоте использования интернета в профессиональной деятельности относительно равномерное. Наибольшая доля использует сеть ежедневно (33%), далее следуют те, кто использует её крайне редко (29.5%), постоянно (22.5%) и не используют вообще (15%).

Код:

#6.3

```
dev.new()
```

```
par(mfrow = c(2, 2))
```

```
x <- table(df$"Activity level (level)"[(df$"Gender"=="1")&(df$"Group"=="1")])
```

```
piepercent <- round(100*x/sum(x), 1)
```

```
pie(x,piepercent,main="Мужчины первой группы", col=c("red",  
"blue","green"),clockwise=TRUE)
```

```
legend("topright", c("High","Low","Medium"), fill =c("red", "blue","green"))
```

```
x <- table(df$"Activity level (level)"[(df$"Gender"=="1")&(df$"Group"=="2")])
```

```
piepercent <- round(100*x/sum(x), 1)
```

```
pie(x,piepercent,main="Мужчины второй группы", col=c("red",  
"blue","green"),clockwise=TRUE)
```

```
legend("topright", c("High","Low","Medium"), fill =c("red", "blue","green"))
```

```
x <- table(df$"Activity level (level)"[(df$"Gender"=="2")&(df$"Group"=="1")])
```

```
piepercent <- round(100*x/sum(x), 1)
```

```
pie(x,piepercent,main="Женщины первой группы", col=c("red",  
"blue","green"),clockwise=TRUE)
```

```
legend("topright", c("High","Low","Medium"), fill =c("red", "blue","green"))
```

```
x <- table(df$"Activity level (level)"[(df$"Gender"=="2")&(df$"Group"=="1")])
```


```
piepercent <- round(100*x/sum(x), 1)
```

```
pie(x,piepercent,main="Женщины второй группы", col=c("red",  
"blue","green"),clockwise=TRUE)
```


```
legend("topright", c("High","Low","Medium"), fill =c("red", "blue","green"))
```

Результат выполнения кода представлен на рис.4.


Мужчины первой группы



Мужчины второй группы



Женщины первой группы



Женщины второй группы




Рисунок 4 - категориальная радиальная диаграмма.

Код:

#6.4

dev.new()

par(mfrow = c(2, 2))

barplot(table(df\$"Activity level"
(score)"[(df\$"Gender"=="1")&(df\$"Group"=="1")]),col=c("red"),main="Мужчины первой
группы",xlab="Степень активности", ylab="Количество наблюдений")

barplot(table(df\$"Activity level"
(score)"[(df\$"Gender"=="1")&(df\$"Group"=="2")]),col=c("blue"),main="Мужчины второй
группы",xlab="Степень активности", ylab="Количество наблюдений")

barplot(table(df\$"Activity level"
(score)"[(df\$"Gender"=="2")&(df\$"Group"=="1")]),col=c("green"),main="Женщины первой
группы",xlab="Степень активности", ylab="Количество наблюдений")

barplot(table(df\$"Activity level"
(score)"[(df\$"Gender"=="2")&(df\$"Group"=="2")]),col=c("yellow"),main="Женщины второй
группы",xlab="Степень активности", ylab="Количество наблюдений")

Результат выполнения кода представлен на рис.5.




Рисунок 5 – категориальная столбиковая диаграмма

Активность в зависимости от пола и группы (круговые и столбиковые диаграммы):

- У мужчин первой группы преобладает высокий уровень активности (81.1%), у женщин первой группы этот показатель еще выше (87.3%).
- Во второй группе картина меняется: у мужчин преобладает низкий уровень активности (45%), высокий составляет 32.5%. У женщин второй группы высокий уровень активности сохраняется (87.3%).
- Столбиковые диаграммы подтверждают, что оценки активности первой группы сосредоточены в верхнем диапазоне, тогда как у второй группы оценки распределены более равномерно.

Код:

```
#6.5
```

```
dev.new()
```

```
boxplot(df$"Average income" ~ df$"Gender", xlab = "Пол", ylab = "Средний доход", data = df)
```

Результат выполнения кода представлен на рис.6.




Рисунок 6 - Диаграмма размаха (Средний доход от пола).

Медианный доход и разброс значений у мужчин (Пол 1) немного выше, чем у женщин (Пол 2), однако значительных различий, судя по визуальному перекрытию "ящиков", не наблюдается.

Код:

#6.6

dev.new()

par(mfrow = c(2, 3))

hist(df\$"Age", freq=FALSE, breaks=12,xlabel="Возраст",main="Возраст")

hist(df\$"Work experience", freq=FALSE, breaks=12,xlabel="Стаж работы",main="Стаж работы")

hist(df\$"Average income", freq=FALSE, breaks=12,xlabel="Средний доход",main="Средний доход")

hist(df\$"Average number of pages", freq=FALSE, breaks=12,xlabel="Среднее количество просматриваемых страниц в месяц",main="Среднее количество просматриваемых страниц в месяц")

hist(df\$"Activity level (score)", freq=FALSE, breaks=12,xlabel="Степень активности",main="Степень активности")

Результат выполнения кода представлен на рис.7.




Рисунок 7 - Гистограммы количественных признаков.

Графики для признаков "Возраст", "Стаж работы", "Средний доход" и "Количество просматриваемых страниц" имеют ярко выраженный бимодальный характер. Это подтверждает наличие двух принципиально разных групп в выборке. Признак "Степень активности" имеет распределение, скошенное влево - отрицательная асимметрия.

Код:

#6.7

```
dev.new()
```

```
par(mfrow = c(2, 2))
```

```
barplot(table(df$ "Activity level  
(score)"[(df$ "Gender"=="1")&(df$ "Group"=="1")]),col=c("red"),main="Мужчины первой  
группы",xlab="Степень активности", ylab="Количество наблюдений")
```

```
barplot(table(df$ "Activity level  
(score)"[(df$ "Gender"=="1")&(df$ "Group"=="2")]),col=c("blue"),main="Мужчины второй  
группы",xlab="Степень активности", ylab="Количество наблюдений")
```

```
barplot(table(df$ "Activity level  
(score)"[(df$ "Gender"=="2")&(df$ "Group"=="1")]),col=c("green"),main="Женщины первой  
группы",xlab="Степень активности", ylab="Количество наблюдений")
```

```
barplot(table(df$ "Activity level  
(score)"[(df$ "Gender"=="2")&(df$ "Group"=="2")]),col=c("yellow"),main="Женщины второй  
группы",xlab="Степень активности", ylab="Количество наблюдений")
```

Результат выполнения кода представлен на рис.8.




Рисунок 8 - Матричный график.

Бимодальность структуры данных отчетливо видна практически на каждом пересечении. Идеальная линейная зависимость наблюдается между "Стажем работы" и "Количеством просматриваемых страниц", что указывает на дублирование или жесткую детерминированность этих переменных. Также прослеживается положительная корреляция между возрастом, стажем и доходом.

4. Корреляционный анализ данных

4.1 Проверка гипотезы о нормальном законе распределения (НЗР)

Для проверки гипотезы о соответствии распределения признака нормальному закону был выбран количественный признак "Average income" (Средний доход).

Использованный код:

```
#7.1
print(pearson.test(df$"Average income"))
print(ad.test(df$"Average income"))
print(shapiro.test(df$"Average income"))
plotNormalHistogram(df$"Average income", xlab="Средний доход", ylab="Количество
наблюдений", length = 1000, breaks = seq(min(df$"Average income"), max(df$"Average
income"),length.out = 7))
```

Результаты тестов:

```
Pearson chi-square normality test
data: df$"Average income"

P = 194.06, p-value < 2.2e-16
> print(ad.test(df$"Average income"))
Anderson-Darling test of goodness-of-fit
Null hypothesis: uniform distribution
Parameters assumed to be fixed
data: df$"Average income"

An = Inf, p-value = 3e-06
> print(shapiro.test(df$"Average income"))
Shapiro-wilk normality test
data: df$"Average income"

W = 0.8733, p-value = 6.767e-12
```




Рисунок 9 - гистограмма с наложением кривой НЗР

Выводы о типе распределения рис.9.:

Во всех трех статистических тестах (Пирсона, Андерсона-Дарлинга, Шапиро-Уилка) полученное значение p-value значительно меньше уровня значимости 0.05. Следовательно, нулевая гипотеза о нормальном распределении отвергается. Графическая иллюстрация (гистограмма с наложением кривой НЗР) также подтверждает этот вывод:

реальное распределение признака "Средний доход" имеет ярко выраженную положительную правостороннюю асимметрию и не описывается колоколообразной кривой Гаусса. В терминах прикладной задачи это означает, что большая часть пользователей имеет доход ниже среднего, в то время как пользователи с очень высоким доходом (в правой части графика) встречаются реже, образуя длинный хвост распределения.

4.2 Оценка степени взаимосвязи между всеми количественными признаками (Пирсон, Спирмен, Кендалл)

Были рассчитаны матрицы парных коэффициентов корреляции Пирсона, Спирмена и Кендалла для всех числовых признаков: "Age", "Average income", "Work experience", "Average number of pages", "Activity level (score)".

Использованный код:

```
# 7.2 Матрицы корреляций
M <- df[,unlist(lapply(df, is.numeric))]
N1<-cor(M, use="pairwise.complete.obs",method="pearson")
N2<-cor(M, use="pairwise.complete.obs",method="spearman")
N3<-cor(M, use="pairwise.complete.obs",method="kendall")
```

Результаты представлены на рис.10.

Выводы по матрицам корреляций (на основе матриц N1, N2, N3):

- Возраст (Age) и Доход (Average income): наблюдается сильная положительная связь (Пирсон ~0.83, Спирмен ~0.79, Кендалл ~0.59). Чем старше пользователь, тем выше его средний доход.
- Возраст (Age) и Стаж (Work experience): наблюдается очень сильная положительная связь (Пирсон ~0.90, Спирмен ~0.88, Кендалл ~0.72).
- Стаж (Work experience) и Просмотры страниц (Average number of pages): Связь практически функциональная (Пирсон = 1.00, Спирмен ~1.00, Кендалл ~0.98). Это указывает либо на то, что эти переменные математически выводятся друг из друга в рамках предоставленной БД, либо на то, что стаж работы в сети жестко детерминирует объем потребляемого контента.
- Активность (Activity level) и другие признаки: наблюдается умеренная и сильная отрицательная корреляция. Наиболее сильная обратная связь у активности с доходом (Пирсон = -0.79). Чем выше доход (и, соответственно, возраст и стаж), тем ниже активность участия пользователя в интернет-опросах.




Рисунок 10 - матрицы парных коэффициентов корреляции Пирсона, Спирмена и Кендалла

4.3 Оценка статистической значимости коэффициента корреляции Пирсона

Для проверки значимости была выбрана пара признаков: "Work experience" (Стаж работы) и "Average number of pages" (Среднее количество страниц).

Использованный код:

```
# 7.3 Проверка значимости
```

```
print(cor.test(df$"Work experience",df$"Average number of pages", method="pearson"))
```

Результат:

```
> #7.3
```

```
> print(cor.test(df$"work experience",df$"Average number of pages", method="pearson"))
```

Pearson's product-moment correlation

data: df\$"Work experience" and df\$"Average number of pages"

t = 516.49, df = 198, p-value < 2.2e-16

alternative hypothesis: true correlation is not equal to 0

95 percent confidence interval:

0.9995096 0.9997195

sample estimates:

cor

0.9996291

Выводы о статистической значимости:

Так как p-value практически равно нулю (значительно меньше 0.05), мы отвергаем нулевую гипотезу об отсутствии связи. Корреляция является статистически значимой. В терминах прикладной задачи существует доказанная, практически прямая линейная ($r \approx 1$) зависимость между стажем работы и средним количеством просматриваемых страниц в месяц.

4.4 Матрицы частных коэффициентов корреляции

Были рассчитаны частные коэффициенты корреляции, которые показывают силу связи между двумя переменными при устранении (фиксации) влияния остальных переменных из набора M. Результат на рис.11.

Использованный код:

```
# 7.4 Частные корреляции
```

```
C1<-pcor(M) # Пирсон
```

```
C2<-pcor(M, method="spearman")
```

```
C3<-pcor(M, method="kendall")
```




Рисунок 11 - матрицы C1

При расчете частных корреляций картина связей кардинально меняется.

- Activity level и Average income: Частная отрицательная корреляция остается очень сильной и статистически значимой (-0.95, p-value = 6.89e-101). Это говорит о том, что падение активности напрямую связано с ростом дохода, независимо от возраста и стажа пользователя.
- Work experience и Average number of pages: Частная корреляция остается практически идеальной (0.993, p-value = 8.14e-186).

- Исчезновение связей: Связи между возрастом и доходом, возрастом и стажем, которые казались сильными при парной корреляции (раздел 4.2), при вычислении частных корреляций становятся близкими к нулю и статистически незначимыми ($p\text{-value} > 0.05$). Это означает, что первоначальная сильная связь объяснялась влиянием других скрытых переменных, присутствующих в модели, и при их фиксации прямая зависимость отсутствует.

4.5 Графическое представление матрицы коэффициентов корреляции с тепловой картой

Использованный код:

```
# 7.5 Тепловая карта
```

```
col <- colorRampPalette(c("#BB4444", "#EE9988", "#FFFFFF", "#77AADD", "#4477AA"))
corrplot(N1, method="color", col=NULL, type="upper", order="hclust",
  addCoef.col = "black", tl.col="black", tl.srt=45,
  sig.level = 0.01, insig = "blank",
  diag=FALSE)
```

Выводы по графику:

Матричный график с тепловой картой (рис. 12) наглядно иллюстрирует силу и направление связей. Темно-синие квадраты в нижней части треугольника подтверждают сильную положительную корреляцию (от 0.77 до 1.00) в кластере признаков: стаж, возраст, количество страниц и доход. Темно-красный квадрат в верхнем левом углу визуализирует сильную отрицательную корреляцию (-0.79) между уровнем активности в опросах и средним доходом.



Рисунок 12 – тепловая карта

5. Исследование взаимосвязей между количественными и качественными признаками

Использованный код:

```
# 8. Дисперсионный анализ и критерий Краскела-Уоллиса
aov_model <- aov(df$"Work experience" ~ df$"Group", data=df)
summary(aov_model)
kruskal.test(df$"Work experience" ~ df$"Group", data=df)
```

Результаты:

```
> #8
> aov_model<-aov(df$"Work experience"~df$"Group",data=df)
> summary(aov_model)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
df\$Group	1	7196	7196	467.8	<2e-16 ***
Residuals	198	3046	15		

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> kruskal.test(df$"Work experience"~df$"Group",data=df)
```

kruskal-wallis rank sum test
data: df\$"work experience" by df\$Group
kruskal-wallis chi-squared = 140.04, df = 1, p-value < 2.2e-16

Поскольку в обоих статистических тестах полученное значение p-value практически равно нулю (и многократно меньше стандартного уровня значимости 0.05), нулевая гипотеза о равенстве средних и медиан в группах отвергается.

В терминах прикладной задачи это свидетельствует о наличии мощной и статистически значимой взаимосвязи между принадлежностью потребителя к определенной группе и его стажем использования услуги. Качественный признак (Группа) жестко детерминирует значения количественного признака (Стаж работы). Это полностью согласуется с предыдущими наблюдениями: рынок четко сегментирован на две категории потребителей с принципиально разным потребительским опытом.

6. Исследование взаимосвязей между качественными признаками

Использованный код:

```
#9
factor_names<-names(df[,unlist(lapply(df, is.factor))])
chi_results<-matrix(NA,nrow = length(factor_names),ncol=length(factor_names))
colnames(chi_results)<-c(factor_names )
rownames(chi_results)<-c(factor_names )
for (col_name in factor_names){
  for (col_name2 in factor_names){
    chi_results[col_name,col_name2] <-
      chisq.test(table(df[,col_name],df[,col_name2]))$p.value
  }
}
chi_results

fisher_results<-matrix(NA,nrow = length(factor_names),ncol=length(factor_names))
colnames(fisher_results)<-c(factor_names )
rownames(fisher_results)<-c(factor_names )
for (col_name in factor_names){
  for (col_name2 in factor_names){
    fisher_results[col_name,col_name2] <-
      fisher.test(table(df[,col_name],df[,col_name2]), workspace = 2e7)$p.value
  }
}
fisher_results
```

Результаты:

> chi_results

	Group	Gender	Professional specialization
Group	1.543120e-44	7.713309e-01	1.319825e-01
Gender	7.713309e-01	1.724481e-44	1.426619e-13
Professional specialization	1.319825e-01	1.426619e-13	2.094185e-123
Activity level (level)	2.325453e-14	5.142547e-01	7.335508e-01
	2.781632e-85	2.325453e-14	5.142547e-01

> fisher_results

	Group	Gender	Professional specialization
Group	2.208761e-59	7.714389e-01	1.341208e-01
Gender	7.714389e-01	2.235999e-57	2.554992e-15
Professional specialization	1.341208e-01	2.554992e-15	3.037254e-114
Activity level (level)	3.459409e-17	5.040501e-01	7.398467e-01
	5.787876e-81	3.459409e-17	5.040501e-01

В ходе вычисления критерия хи-квадрат Пирсона было получено системное предупреждение: «аппроксимация на основе хи-квадрат может быть неправильной». Это указывает на наличие малых ожидаемых частот в некоторых ячейках таблиц сопряженности. В таких случаях результаты классического хи-квадрат могут быть смещены, поэтому для формулирования окончательных выводов приоритет отдается результатам точного критерия Фишера.

Связь между группой потребителей и их активностью (Group — Activity level): Выявлена статистически значимая связь ($p\text{-value} = 3.45e-17 < 0.05$). Принадлежность потребителя к первой или второй группе (что, как было выяснено ранее, сильно коррелирует с возрастом и доходом) напрямую влияет на его качественную оценку активности в интернет-опросах.

Связь между полом и профессиональной специализацией (Gender — Professional specialization): Выявлена статистически значимая связь ($p\text{-value} = 2.55e-15 < 0.05$). Частота использования сети Интернет в профессиональной деятельности существенно отличается у мужчин и женщин в рамках исследуемой выборки.

Отсутствие значимых связей: Для всех остальных пар качественных признаков гипотеза о независимости не отвергается ($p\text{-value} > 0.05$).

➤ Пол потребителя не влияет на его склонность участвовать в опросах ($p\text{-value} = 0.504$). Различия в активности диктуются именно принадлежностью к группе, а не гендером.

➤ Частота использования интернета по работе (Professional specialization) не зависит от группы потребителя ($p\text{-value} = 0.134$) и никак не сказывается на желании проходить интернет-опросы (Activity level, $p\text{-value} = 0.739$).

➤ Группы сформированы сбалансированно относительно пола: статистически значимой связи между переменными Group и Gender нет ($p\text{-value} = 0.771$).

7. Матричные графики, построенные функцией `ggpairs()`; описание и анализ графиков

Для комплексной визуализации взаимосвязей между различными типами признаков (количественными и качественными) с разделением по целевым группам (Group 1 и Group 2) была использована функция `ggpairs` из пакета `GGally`.

Использованный код:

```
#10
ggpairs(df, columns = 2:5, aes(color = Group, alpha = 0.5))
ggpairs(df, columns = c(2,6,9), aes(color = Group, alpha = 0.5))
ggpairs(df, columns = c(3:5,7:8), aes(color = Group, alpha = 0.5))
ggpairs(df, columns = c(2,8:9), aes(color = Group, alpha = 0.5))
```

На всех графиках красный цвет соответствует Группе 1, бирюзовый — Группе 2. График количественных признаков (Возраст, Доход, Стаж, Страницы, Активность) (рис. 13):

- Распределения (главная диагональ): Графики плотности четко демонстрируют бимодальность общей выборки. Группа 1 (молодежь) имеет узкие, высокие пики распределения в зоне низкого возраста, небольшого стажа, низкого дохода и меньшего количества просматриваемых страниц. Распределения Группы 2 более размыты (большая дисперсия) и смещены вправо. Исключением является признак `Activity level (score)`: здесь пик Группы 1 находится правее (выше активность), а Группа 2 имеет более равномерное, растянутое распределение.
- Диаграммы рассеяния и корреляции (вне диагонали): Подтверждается идеальная линейная зависимость между стажем (`Work experience`) и количеством страниц (`Average number of pages`) во всех группах (`corr = 0.997` для Группы 1; `corr = 0.999` для Группы 2). Также визуально хорошо разделимы кластеры двух групп при сопоставлении возраста с доходом или стажем: Группа 1 образует плотное облако в нижнем левом углу, Группа 2 — более разреженное облако выше и правее.




Рисунок 13 - График количественных признаков.

График качественных признаков (Пол, Специализация, Уровень активности) (рис. 14):

- Мозаичные графики (mosaic plots) иллюстрируют структуру категориальных данных.
- Наиболее яркий вывод: уровень активности high (высокий) доминирует в Группе 1 (красный цвет) независимо от пола и профессиональной специализации.
- В Группе 2 (бирюзовый цвет) значительную долю занимают уровни активности Low (низкий) и Medium (средний).




Рисунок 14 - График качественных признаков (Пол, Специализация, Уровень активности)

График показателей активности (Пол, Баллы активности, Уровень активности) (рис. 15):

- Диаграммы размаха показывают, что у потребителей с качественной оценкой High (высокий уровень активности) медианный балл находится в районе 80-85 баллов, и здесь представлены в основном пользователи Группы 1.
- Пользователи с оценкой Low (низкий уровень активности) имеют медианный балл около 55, и это исключительно представители Группы 2.
- Распределение баллов активности (Activity level (score)) в зависимости от пола внутри групп идентично.

Общий вывод по матричным графикам: Визуализация ggpairs успешно подтвердила гипотезу о строгой сегментации потребителей на две группы. Группа 1 — это более молодые пользователи с меньшим доходом и стажем, потребляющие меньше страниц, но проявляющие высокую, стабильную активность в опросах. Группа 2 — старше, с

большим доходом и стажем, они потребляют значительно больше контента, но их вовлеченность в опросы ниже и варьируется сильнее. Гендерные различия в данной выборке не играют существенной роли в формировании потребительского поведения.

8. Общие выводы о силе и направлении связи между исследуемыми признаками в терминах решаемой задачи для первой и второй групп

В ходе корреляционного дисперсионного и визуального анализа рынка потребителей услуги «Подключение к сети Интернет» были выявлены следующие закономерности в силе и направлении связей между признаками:

- Связь потребления услуг и стажа (Сильная, положительная): Выявлена практически идеальная прямая зависимость ($r \approx 1.0$) между стажем использования услуги и средним количеством просматриваемых страниц в месяц. Это справедливо для обеих групп: чем дольше клиент пользуется сетью, тем выше объем потребляемого им контента.
- Связь дохода с возрастом и стажем (Сильная, положительная): Наблюдается устойчивая положительная корреляция ($r \approx 0.8 — 0.9$) между возрастом потребителя, его стажем и средним доходом. При этом дисперсионный анализ подтвердил, что принадлежность к целевой Группе жестко детерминирует эти показатели.
- Связь активности с доходом и стажем (Сильная, отрицательная): Обнаружена сильная обратная зависимость ($r \approx -0.79$, частная корреляция до -0.95) между уровнем активности в интернет-опросах и средним доходом потребителя. Чем выше доход клиента, тем ниже вероятность его участия в опросах.
- Влияние гендера (Отсутствует или слабое): Пол потребителя не оказывает статистически значимого влияния на объемы потребляемого контента, уровень дохода или вовлеченность в опросы. Единственная выявленная зависимость — различие в частоте использования сети в профессиональных целях между мужчинами и женщинами.

9. Выводы по работе в произвольной форме

В рамках проведенного статистического исследования базы данных (200 наблюдений) был выполнен полный цикл разведочного, графического и корреляционного анализа.

Главным итогом работы является подтверждение гипотезы о строгой бимодальности (неоднородности) исследуемого рынка. Аудитория четко сегментируется на два непересекающихся кластера с принципиально разным паттерном поведения:

- Сегмент 1 (Молодежная аудитория): Пользователи в возрасте около 20–25 лет с небольшим стажем и доходом ниже среднего. Они просматривают относительно небольшой объем страниц (около 1200 в месяц), однако демонстрируют стабильно высокую и предсказуемую активность во взаимодействии с провайдером (участие в опросах, обратная связь).
- Сегмент 2 (Взрослая аудитория): Пользователи в возрасте около 40 лет с высоким, но сильно варьирующимся доходом и солидным стажем. Они являются основными потребителями трафика (около 3000 страниц в месяц), однако их уровень вовлеченности в интерактивные мероприятия и опросы оценивается как низкий или средний.

Для провайдера услуги «Подключение к сети Интернет» это означает необходимость применения дифференцированных стратегий: монетизация через объем трафика и дополнительные услуги наиболее эффективна для второй группы, в то время как сбор данных, тестирование новых функций и маркетинговые опросы целесообразно таргетировать на первую группу.

Приложение с полным кодом на R

```
library(nortest)
library(goftest)
library(rcompanion)
library(ppcor)
library(corrplot)
library(GGally)
library(ggplot2)

df <- read.csv2("var_15.csv")
df <- df[, -1]

#3
names(df)[names(df) == "Average.income"] <- "Average income"
names(df)[names(df) == "Work.experience"] <- "Work experience"
names(df)[names(df) == "Professional.specialization"] <- "Professional specialization"
names(df)[names(df) == "Average.number.of.pages"] <- "Average number of pages"
names(df)[names(df) == "Activity.level..score."] <- "Activity level (score)"
names(df)[names(df) == "Activity.level..level."] <- "Activity level (level)"

#4
df$"Group" <- as.factor(df$"Group")
df$"Gender" <- as.factor(df$"Gender")
df$"Age" <- as.integer(df$"Age")
df$"Work experience" <- as.numeric(df$"Work experience")
df$"Average income" <- as.numeric(df$"Average income")
df$"Professional specialization" <- as.factor(df$"Professional specialization")
df$"Average number of pages" <- as.integer(df$"Average number of pages")
df$"Activity level (score)" <- as.integer(df$"Activity level (score)")
df$"Activity level (level)" <- as.factor(df$"Activity level (level)")
print(str(df))

#5
print(summary(df))

#6
#6.1
dev.new()
plot(df$"Work experience", df$"Average income", main = "Диаграмма рассеяния", xlab =
"Стаж работы", ylab = "Средний доход", pch = 11)

#6.2
dev.new()
x <- c(summary(df$"Professional specialization"))
piepercent <- round(100*x/sum(x), 1)
pie(x, piepercent, main = "Профессиональная специализация", col = c("red",
"blue", "green", "yellow"), clockwise = TRUE)
legend("topright", c("Не использую", "Крайне редко", "Ежедневно", "Постоянно"), fill
=c("red", "blue", "green", "yellow"))
```

#6.3

```
dev.new()
par(mfrow = c(2, 2))
x <- table(df$"Activity level (level)"[(df$"Gender"=="1")&(df$"Group"=="1")])
piepercent <- round(100*x/sum(x), 1)
pie(x,piepercent,main="Мужчины первой группы", col=c("red",
"blue","green"),clockwise=TRUE)
legend("topright", c("High","Low","Medium"), fill =c("red", "blue","green"))
x <- table(df$"Activity level (level)"[(df$"Gender"=="1")&(df$"Group"=="2")])
piepercent <- round(100*x/sum(x), 1)
pie(x,piepercent,main="Мужчины второй группы", col=c("red",
"blue","green"),clockwise=TRUE)
legend("topright", c("High","Low","Medium"), fill =c("red", "blue","green"))
x <- table(df$"Activity level (level)"[(df$"Gender"=="2")&(df$"Group"=="1")])
piepercent <- round(100*x/sum(x), 1)
pie(x,piepercent,main="Женщины первой группы", col=c("red",
"blue","green"),clockwise=TRUE)
legend("topright", c("High","Low","Medium"), fill =c("red", "blue","green"))
x <- table(df$"Activity level (level)"[(df$"Gender"=="2")&(df$"Group"=="1")])
piepercent <- round(100*x/sum(x), 1)
pie(x,piepercent,main="Женщины второй группы", col=c("red",
"blue","green"),clockwise=TRUE)
legend("topright", c("High","Low","Medium"), fill =c("red", "blue","green"))
```

#6.4

```
dev.new()
par(mfrow = c(2, 2))
barplot(table(df$"Activity level
(score)"[(df$"Gender"=="1")&(df$"Group"=="1")]),col=c("red"),main="Мужчины первой
группы",xlab="Степень активности", ylab="Количество наблюдений")
barplot(table(df$"Activity level
(score)"[(df$"Gender"=="1")&(df$"Group"=="2")]),col=c("blue"),main="Мужчины второй
группы",xlab="Степень активности", ylab="Количество наблюдений")
barplot(table(df$"Activity level
(score)"[(df$"Gender"=="2")&(df$"Group"=="1")]),col=c("green"),main="Женщины первой
группы",xlab="Степень активности", ylab="Количество наблюдений")
barplot(table(df$"Activity level
(score)"[(df$"Gender"=="2")&(df$"Group"=="2")]),col=c("yellow"),main="Женщины второй
группы",xlab="Степень активности", ylab="Количество наблюдений")
```

#6.5

```
dev.new()
boxplot(df$"Average income" ~ df$"Gender", xlab = "Пол", ylab = "Средний доход", data =
df)
```

#6.6

```
dev.new()
par(mfrow = c(2, 3))
hist(df$"Age", freq=FALSE, breaks=12,xlabel="Возраст",main="Возраст")
hist(df$"Work experience", freq=FALSE, breaks=12,xlabel="Стаж работы",main="Стаж
работы")
```

```
hist(df$"Average income", freq=FALSE, breaks=12,xlabel="Средний доход",main="Средний
доход")
hist(df$"Average number of pages", freq=FALSE, breaks=12,xlabel="Среднее количество
просматриваемых страниц в месяц",main="Среднее количество просматриваемых страниц
в месяц")
hist(df$"Activity level (score)", freq=FALSE, breaks=12,xlabel="Степень
активности",main="Степень активности")
```

#6.7

```
dev.new()
```

```
pairs(~df$"Age"+df$"Work experience"+df$"Average income"+df$"Average number of
pages"+df$"Activity level (score)",data=df,main="Матричный график", col="red")
```

#7

#7.1

```
print(pearson.test(df$"Average income"))
print(ad.test(df$"Average income"))
print(shapiro.test(df$"Average income"))
plotNormalHistogram(df$"Average income", xlab="Средний доход", ylab="Количество
наблюдений", length = 1000, breaks = seq(min(df$"Average income"), max(df$"Average
income"),length.out = 7))
```

#7.2

```
M <- df[,unlist(lapply(df, is.numeric))]
N1<-cor(M, use="pairwise.complete.obs",method="pearson")
N2<-cor(M, use="pairwise.complete.obs",method="spearman")
N3<-cor(M, use="pairwise.complete.obs",method="kendall")
View(N1)
View(N2)
View(N3)
```

#7.3

```
print(cor.test(df$"Work experience",df$"Average number of pages", method="pearson"))
```

#7.4

```
C1<-pcor(M)
View(C1$estimate)
View(C1$p.value)
C2<-pcor(M, method="spearman")
C3<-pcor(M, method="kendall")
```

#7.5

```
col <- colorRampPalette(c("#BB4444", "#EE9988", "#FFFFFF", "#77AADD",
"#4477AA"))
corrplot(N1, method="color", col=NULL,type="upper", order="hclust",
addCoef.col = "black", tl.col="black", tl.srt=45,
sig.level = 0.01, insig = "blank",
diag=FALSE
)
```

#8

```
aov_model<-aov(df$"Work experience"~df$"Group",data=df)
```

```

summary(aov_model)
kruskal.test(df$"Work experience"~df$"Group",data=df)

#9
table_P9<-table(df$"Activity level (level)", df$"Professional specialization")
View(table_P9)
prop.table(table_P9)
addmargins(table_P9)
chisq.test(table(df$"Activity level (level)",df$"Gender"))
fisher.test(table(df$"Activity level (level)",df$"Gender"))

factor_names<-names(df[,unlist(lapply(df, is.factor))])
chi_results<-matrix(NA,nrow = length(factor_names),ncol=length(factor_names))
colnames(chi_results)<-c(factor_names )
rownames(chi_results)<-c(factor_names )
for (col_name in factor_names){
  for (col_name2 in factor_names){
    chi_results[col_name,col_name2] <-
      chisq.test(table(df[,col_name],df[,col_name2]))$p.value
  }
}
chi_results

fisher_results<-matrix(NA,nrow = length(factor_names),ncol=length(factor_names))
colnames(fisher_results)<-c(factor_names )
rownames(fisher_results)<-c(factor_names )
for (col_name in factor_names){
  for (col_name2 in factor_names){
    fisher_results[col_name,col_name2] <-
      fisher.test(table(df[,col_name],df[,col_name2]), workspace = 2e7)$p.value
  }
}
fisher_results

#10
ggpairs(df,columns = 2:5, aes(color = Group,alpha = 0.5))
ggpairs(df,columns = c(2,6,9), aes(color = Group,alpha = 0.5))
ggpairs(df,columns = c(3:5,7:8), aes(color = Group,alpha = 0.5))
ggpairs(df,columns = c(2,8:9), aes(color = Group,alpha = 0.5))

```